

Cas Kaggle: Predicció del Valor de Jugadors FIFA

Roger Garcia^{a,1} and Héctor Sánchez^{b,2}

^a1706880
^b1704248

Abstract—En aquest projecte assumim el rol d'un equip de *Data Scientists* contractat per un club de futbol d'elit. L'objectiu és desenvolupar un model de *Machine Learning* capaç de predir amb precisió el valor de mercat (*value_euro*) dels jugadors de futbol a partir de les seves estadístiques i característiques físiques. Treballem amb un dataset FIFA amb aproximadament 18 000 jugadors i més de 50 variables. Després d'un procés de neteja, anàlisi exploratòria, enginyeria de característiques i comparació de diversos models de regressió, obtenim un model XGBoost amb un rendiment molt alt ($R^2 \approx 0.975$ i RMSE al voltant d'1 milió d'euros), i identifiquem quines variables són més rellevants per explicar el valor de mercat.

Keywords—FIFA, futbol, predicció de valor, regressió, XGBoost, Machine Learning

Contents

1	Introducció	1
2	Dades i Enginyeria de Característiques	1
3	Anàlisi Exploratoria	1
4	Models i Resultats	2
5	Avaluació i Interpretació	2
6	Conclusions	2

1. Introducció

En aquest treball abordem el problema de la predicció del valor de mercat de jugadors de futbol a partir de dades del videojoc FIFA. Suposem que treballem per a la direcció esportiva d'un club d'elit, i que el nostre model servirà com a eina de suport per:

- Identificar jugadors infravalorats o sobrevalorats.
- Ajudar en la presa de decisions de fitxatges.
- Analitzar l'impacte de les estadístiques esportives en el valor econòmic.

	name	full_name	birth_date	age	height_cm	weight_kgs	positions	nationality	o
0	L. Messi	Lionel Andrés Messi Cuccittini	6/24/1987	31	170.18	72.1	CF,RW,ST	Argentina	
1	C. Eriksen	Christian Dannemann Eriksen	2/14/1992	27	154.94	76.2	CAM,RM,CM	Denmark	
2	P. Pogba	Paul Pogba	3/15/1993	25	190.50	83.9	CM,CAM	France	
3	L. Insigne	Lorenzo Insigne	6/4/1991	27	162.56	59.0	LW,ST	Italy	
4	K. Koulibaly	Kalidou Koulibaly	6/20/1991	27	187.96	88.9	CB	Senegal	

Figure 1. Distribució del valor de mercat o visió general del dataset.

2. Dades i Enginyeria de Característiques

El dataset `fifa_players.csv` conté unes 17954 files amb 51 columnes corresponents a variables demogràfiques, atributs tècnics i estadístiques esportives.

Durant la fase de preprocessament:

- Eliminem registres incomplets.
- Codifiquem variables categòriques com la posició.

- Normalitzem variables numèriques. 17
- Creem les variables `primary_position` i `position_count`. 18




Figure 2. Correlacions entre variables o anàlisi per posicions.

3. Anàlisi Exploratoria

La variable `value_euro` presenta una forta asimetria: pocs jugadors concentren valors molt elevats.

Existeix una correlació clara entre el valor i variables com:

- `overall rating` 23
- `potential` 24
- `age` 25

Per a comparar perfils segons posició s'utilitzen diferents gràfics. 26




Figure 3. Exemple de gràfic.

Aquí podem veure la matriu de correlacions:




Figure 4. Matriu de correlacions.

- potential
- age
- atributs ofensius

En aquest projecte hem aconseguit:

Netejar i preparar un dataset complex de jugadors FIFA. Crear noves variables útils com primaryposition. Entrenar un model XGBoost capaç de predir el valor de mercat amb alta precisió ($R^2 > 0.95$). Identificar que variables com overallrating, potential i age són determinants per al valor. Aquest treball demostra el potencial del *Machine Learning* aplicat a l'anàlisi econòmica de l'esport professional.




Figure 6. XGBoost.

4. Models i Resultats

S'entrenen tres models:

- Regressió Lineal
- Random Forest
- XGBoost

Resultats en conjunt de test:

- Linear Regression: $R^2 \approx 0.64$, RMSE ≈ 3.7 M€.
- Random Forest: $R^2 \approx 0.96$, RMSE ≈ 1.1 M€.
- XGBoost: $R^2 \approx 0.98$, RMSE ≈ 0.96 M€.

	Model	RMSE	MAE	R2
2	XGBoost	9.646048e+05	1.830750e+05	0.975015
1	Random Forest	1.154216e+06	2.039029e+05	0.964226
0	Linear Regression	3.657027e+06	1.916931e+06	0.640875

Figure 5. Comparació de models.




Figure 7. SHAP.

5. Avaluació i Interpretació

Analitzem els errors del model final per entendre on falla i quines variables són les més influents(Figure 6)
Utilitzem SHAP per explicar quines característiques tenen més pes en la decisió del model.(Figure 7)

6. Conclusions

El model XGBoost proporciona una predicció molt precisa del valor de mercat dels jugadors.
Les variables més determinants són:

- overall rating